Answer of Assignment 6
PCA & SVM

2020E8017782032_ 蒲尧

第一部分：计算与证明

1. 有 N 个样本 $x_1, ..., x_N$，每个样本维数 D，希望将样本维数降低到 K，请给出 PCA 算法的计算过程。
2. 根据自己的理解简述结构风险最小化与 VC 维。
3. 请推导出 Hard-Margin SVM 的优化目标。
4. 请解释出 Hinge Loss 在 SVM 中的意义。
5. 简述核方法的基本原理。

第二部分：计算机编程

6. 从 MNIST 数据集中任意选择两类，对其进行 SVM 分类，可调用现有的 SVM 工具如 LIBSVM，展示超参数 C 以及核函数参数的选择过程。

第一部分回答

1. PCA 算法的计算过程：

   (1) 计算数据的均值：$\bar{\boldsymbol{x}} = \frac{1}{N}\sum_{n=1}^{N} \boldsymbol{x}_n$；

   (2) 计算样本的协方差矩阵：$\mathbf{S} = \sum_{n=1}^{N} (x_n - \bar{x})(x_n - \bar{x})^T$；

   (3) 做 D×D 维矩阵 $\mathbf{S}$ 的特征值分解；

   (4) 提取其中最大的 K 个特征值对应的最大的 K 个特征向量 $\vec{u}_1, ..., \vec{u}_K, (s.t. \lambda_1 \geq \lambda_2 \geq ... \geq \lambda_{K-1} \geq \lambda_K \geq)$，得到 D×K 大小的映射矩阵 $\mathbf{U} = [\vec{u}_1, \vec{u}_2, ..., \vec{u}_K]$；

   (5) 将每个样本进行映射：$\boldsymbol{z}_n = \mathbf{U}^T \boldsymbol{x}_n$，得到的 $\boldsymbol{z}_n$ 是 K×1 的向量。

2. (1) 结构风险最小化：在未知的测试集上的错误率达到最小化。$Test\ error\ rate <= train\ error\ rate + f(N, h, p)$

   (2) VC 维：某个空间中给 n 个样本点随机打标签，如果某个模型足够强大能够将其分开，则增加样本个数为 n+1，直到不能分开 n+1，则这个最大的样本点数 n 为该空间的 VC 维。

3. Hard-Margin SVM 的优化目标

点 $\vec{x_i}$ 到直线 $\vec{w}\vec{x}+\vec{b}=0$ 的距离为：

$$d\left(\vec{x_i}\right)=\frac{\left|\vec{w}\vec{x_i}+\vec{b}\right|}{\sqrt{||\vec{w}||_2^2}}$$

$$\begin{cases}\vec{w}\vec{x_i}+\vec{b}\geq 0, & y_i=1;\\ \vec{w}\vec{x_i}+\vec{b}\leq 0, & y_i=-1\end{cases}$$

我们的目标是最大化到直线最近点的距离 d，从而推出参数 $\vec{w},\vec{b}$：

$$\begin{aligned}&\max_{\vec{w},\vec{b}}\min_{\vec{x_i}\in\mathbf{D}} d\\ =&\max_{\vec{w},\vec{b}}\min_{\vec{x_i}\in\mathbf{D}}\frac{\left|\vec{w}\vec{x_i}+\vec{b}\right|}{\sqrt{||\vec{w}||_2^2}}\\ &s.t.\ \forall\vec{x_i}\in\mathbf{D}:\ y_i\left(\vec{w}\vec{x}+\vec{b}\right)\geq 0\end{aligned}$$

我们采用如下策略：

$$\forall\vec{x_i}\in\mathbf{D}:\ \left|\vec{w}\vec{x}+\vec{b}\right|\geq 1$$

我们可以推出：

$$\min_{\vec{x_i}\in\mathbf{D}}\frac{\left|\vec{w}\vec{x_i}+\vec{b}\right|}{\sqrt{||\vec{w}||_2^2}}\geq\min_{\vec{x_i}\in\mathbf{D}}\frac{1}{\sqrt{||\vec{w}||_2^2}}=\frac{1}{\sqrt{||\vec{w}||_2^2}}=\frac{1}{||\vec{w}||}$$

直线两侧都有点，距离 $\times 2$，得到最终优化目标：

$$\max\frac{2}{||\vec{w}||}$$

4. 对于 Soft-margin SVM，优化目标可以写成：

$$\min_{\vec{w},b}\frac{||\vec{w}||^2}{2}+C\sum_{i=1}^{m}\mathscr{L}_{0/1}\left(y_i\left(\vec{w}^T\vec{x}_i+b\right)-1\right)$$

其中，C>0 是一个常数，作为惩罚因子，$\mathscr{L}_{0/1}$ 是“0/1 损失函数”：

$$\mathscr{L}_{0/1}\left(z\right)=\begin{cases}1, & \text{if } z<0;\\ 0, & \text{otherwise}\end{cases}$$

Hinge Loss:

$$\mathscr{L}_{hinge}\left(z\right)=\max\left(0,1-z\right)$$

Hinge Loss 的零区域对应的正是非支持向量的普通样本，从而所有的普通样本都不参与最终超平面的决定；只考虑支持向量。这正是支持向量机最大的优势所在，对训练样本数目的依赖大大减少，从而且提高了训练效率。

5. 核方法：回顾前面得到的公式：

$$\begin{aligned}&\max\sum_{i=1}^{n}\alpha_i-\frac{1}{2}\sum_{i=1,j=1}^{n}\alpha_i\alpha_j y_i y_j x_i x_j\\ &s.t.\ C\geq\alpha_i\geq 0,\ \sum_{i=1}^{n}\alpha_i y_i=0\end{aligned}$$

我们看到计算目标函数时，需要知道 x 的内积。我们引入核函数，一个可以应用于一对输入数据以计算对应特征空间中的内积的函数。对于不能线性分割的数据集，核函数可以将数据升高维度，进行高纬度的内积，寻找高纬度数据的相似性和高纬度的线性分界面。

第二部分回答

代码见如下文件 Python 文件。由图可知：C 过小，欠拟合，准确度较小；C 过大，过拟合，Test 和 Train 的准确率相差会变大。gamma 过小准确度较小，gamma 越大准确度相对变大。

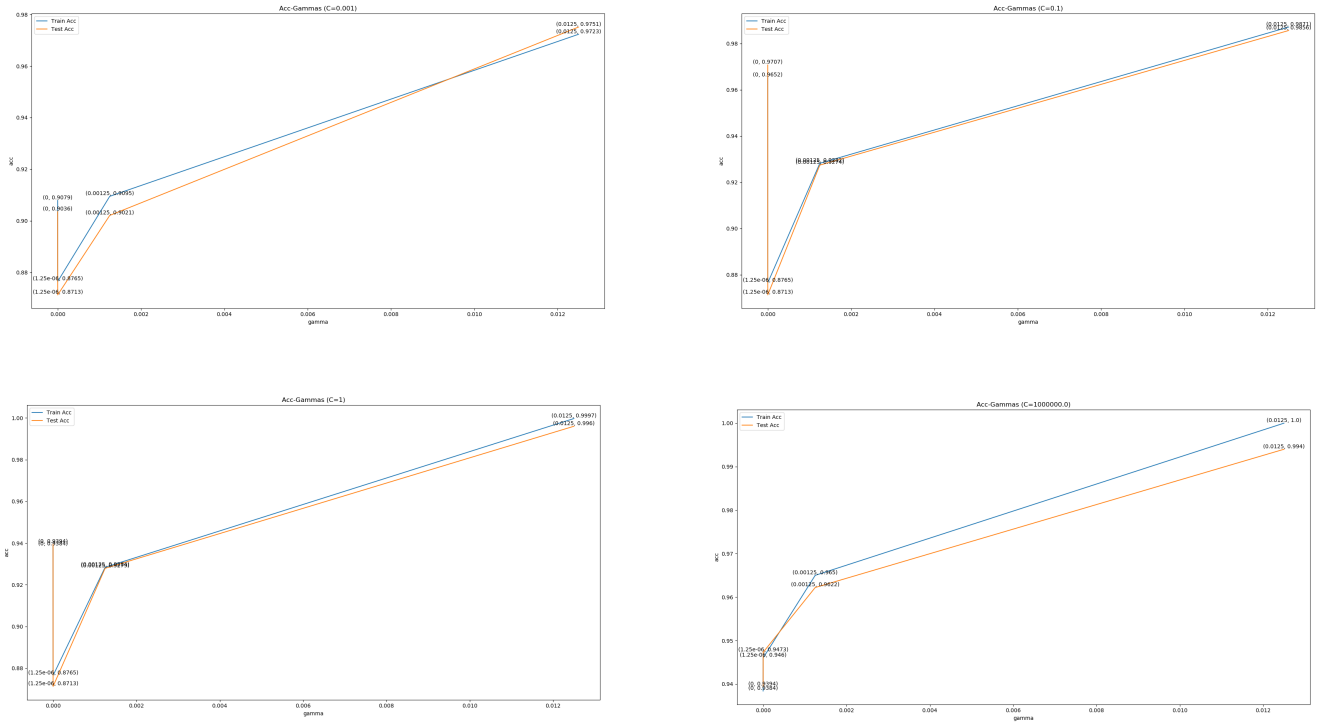

图 1: Acc-gamma-C